

Pourquoi les matrices aléatoires expliquent l'apprentissage ? Un argument d'universalité offert par les GANs

(Gretsi'2019, Lille)

Mohamed El Amine SEDDIK, Mohamed TAMAAZOUSTI, Romain COUILLET

CEA List, France
CentraleSupélec, L2S, Université ParisSaclay, France
GSTATS IDEX DataScience Chair, GIPSA-lab, Université Grenoble-Alpes, France.

29 août 2019



CentraleSupélec

Outline

Introduction

Comportement de la matrice de Gram de vecteurs Gaussiens

Notion de vecteurs concentrés

Definition et propriétés

Données GAN : Un exemple de vecteurs concentrés

Comportement de la matrice de Gram de vecteurs concentrés

Application aux représentations CNN des images GAN

Outline

Introduction

Comportement de la matrice de Gram de vecteurs Gaussiens

Notion de vecteurs concentrés

Definition et propriétés

Données GAN : Un exemple de vecteurs concentrés

Comportement de la matrice de Gram de vecteurs concentrés

Application aux représentations CNN des images GAN

Introduction

En apprentissage machine (ML),

Introduction

En apprentissage machine (ML),

- ▶ Etant donné un ensemble de données

$$X = [x_1, x_2, \dots, x_n] \in \mathbb{R}^{p \times n}$$

Introduction

En apprentissage machine (ML),

- ▶ Etant donné un ensemble de données

$$X = [x_1, x_2, \dots, x_n] \in \mathbb{R}^{p \times n}$$

- ▶ On aimerait réaliser des tâches de

Régression, Classification, Regroupement etc.

Introduction

En apprentissage machine (ML),

- ▶ Etant donné un ensemble de données

$$X = [x_1, x_2, \dots, x_n] \in \mathbb{R}^{p \times n}$$

- ▶ On aimerait réaliser des tâches de

Régression, Classification, Regroupement etc.

- ▶ Et au cœur de ces tâches, on calcule des **similarités**

Introduction

En apprentissage machine (ML),

- ▶ Etant donné un ensemble de données

$$X = [x_1, x_2, \dots, x_n] \in \mathbb{R}^{p \times n}$$

- ▶ On aimerait réaliser des tâches de

Régression, Classification, Regroupement etc.

- ▶ Et au cœur de ces tâches, on calcule des **similarités**

Par exemple : le produit scalaire $x_i^T x_j$

Introduction

En apprentissage machine (ML),

- ▶ Etant donné un ensemble de données

$$X = [x_1, x_2, \dots, x_n] \in \mathbb{R}^{p \times n}$$

- ▶ On aimerait réaliser des tâches de

Régression, Classification, Regroupement etc.

- ▶ Et au cœur de ces tâches, on calcule des **similarités**

Par exemple : le produit scalaire $x_i^T x_j$

Naturellement, la matrice de Gram $X^T X$ apparaît en ML.

Introduction

En apprentissage machine (ML),

- ▶ Etant donné un ensemble de données

$$X = [x_1, x_2, \dots, x_n] \in \mathbb{R}^{p \times n}$$

- ▶ On aimerait réaliser des tâches de

Régression, Classification, Regroupement etc.

- ▶ Et au cœur de ces tâches, on calcule des **similarités**

Par exemple : le produit scalaire $x_i^T x_j$

Naturellement, la matrice de Gram $X^T X$ apparaît en ML.

- ▶ **Comment se comporte t-elle ?**

Outline

Introduction

Comportement de la matrice de Gram de vecteurs Gaussiens

Notion de vecteurs concentrés

Definition et propriétés

Données GAN : Un exemple de vecteurs concentrés

Comportement de la matrice de Gram de vecteurs concentrés

Application aux representations CNN des images GAN

Comportement de la matrice de Gram de vecteurs Gaussiens

- ▶ Si on suppose tous les $x_i \sim \mathcal{N}(0, I_p)$

Comportement de la matrice de Gram de vecteurs Gaussiens

- ▶ Si on suppose tous les $x_i \sim \mathcal{N}(0, I_p)$




Figure: Histogramme des valeurs propres de $\frac{1}{p}X^T X$ pour $n = p = 1000$.

Loi de Marčenko–Pastur [Marčenko, Pastur'67]

Définition (Densité Spectrale Empirique)

La densité spectrale empirique (e.s.d.) μ_n d'une matrice hermitienne $A_n \in \mathbb{R}^{n \times n}$ est donnée par $\mu_n = \frac{1}{n} \sum_{i=1}^n \delta_{\lambda_i(A_n)}$.

Loi de Marčenko–Pastur [Marčenko, Pastur'67]

Définition (Densité Spectrale Empirique)

La densité spectrale empirique (e.s.d.) μ_n d'une matrice hermitienne $A_n \in \mathbb{R}^{n \times n}$ est donnée par $\mu_n = \frac{1}{n} \sum_{i=1}^n \delta_{\lambda_i(A_n)}$.

Théorème (Loi de Marčenko–Pastur)

Soit $X \in \mathbb{R}^{p \times n}$ avec des entrées i.i.d. de moyenne nulle, et de variance 1.

Quand $p, n \rightarrow \infty$ avec $n/p \rightarrow c \in (0, \infty)$, la e.s.d. μ_n de $\frac{1}{p} X^\top X$ satisfait

$$\mu_n \xrightarrow{p.s.} \mu_c$$

où μ_c est une mesure déterministe de densité continue f_c sur un support compacte $[\lambda^-, \lambda^+] = [(1 - \sqrt{c})^2, (1 + \sqrt{c})^2]$

$$f_c(x) = \frac{1}{2\pi cx} \sqrt{(x - \lambda^-)(\lambda^+ - x)}$$

Mélange Gaussien (Modèle spike)

- ▶ Soit $\mu \in \mathbb{R}^p$ tel que $\|\mu\| = \mathcal{O}(1)$

Mélange Gaussien (Modèle spike)

- ▶ Soit $\mu \in \mathbb{R}^p$ tel que $\|\mu\| = \mathcal{O}(1)$
- ▶ Considérons

$$X = [\underbrace{x_1, \dots, x_{\frac{n}{2}}}_{\sim \mathcal{N}(+\mu, I_p)}, \underbrace{x_{\frac{n}{2}+1}, \dots, x_n}_{\sim \mathcal{N}(-\mu, I_p)}]$$

Mélange Gaussien (Modèle spike)

- ▶ Soit $\mu \in \mathbb{R}^p$ tel que $\|\mu\| = \mathcal{O}(1)$
- ▶ Considérons

$$X = [\underbrace{x_1, \dots, x_{\frac{n}{2}}}_{\sim \mathcal{N}(+\mu, I_p)}, \underbrace{x_{\frac{n}{2}+1}, \dots, x_n}_{\sim \mathcal{N}(-\mu, I_p)}]$$

- ▶ Qu'on peut écrire

$$X = \mu y^\top + Z$$

où $y \in \{+1, -1\}^n$ est le vecteur de labels et Z a des entrées i.i.d. $\mathcal{N}(0, 1)$.

Mélange Gaussien (Modèle spike)

- Soit $\mu \in \mathbb{R}^p$ tel que $\|\mu\| = \mathcal{O}(1)$
- Considérons

$$X = [\underbrace{x_1, \dots, x_{\frac{n}{2}}}_{\sim \mathcal{N}(\textcolor{red}{+\mu}, I_p)}, \underbrace{x_{\frac{n}{2}+1}, \dots, x_n}_{\sim \mathcal{N}(\textcolor{blue}{-\mu}, I_p)}]$$

- Qu'on peut écrire

$$X = \mu y^\top + Z$$

où $y \in \{\textcolor{red}{+1}, \textcolor{blue}{-1}\}^n$ est le vecteur de labels et Z a des entrées i.i.d. $\mathcal{N}(0, 1)$.

- On a donc

$$\frac{1}{p} X^\top X = \underbrace{\|\mu\|^2 \bar{y} \bar{y}^\top}_{\text{Information (rang-faible)}} + \underbrace{\frac{1}{p} Z^\top Z}_{\text{Bruit}} + *$$

where $\bar{y} = y / \sqrt{p}$

Mélange Gaussien (Modèle spike)




Figure: Histogramme des valeurs propres de $\frac{1}{p}X^T X$ pour $n = p = 1000$.

Mélange Gaussien (Modèle spike)




Figure: Histogramme des valeurs propres de $\frac{1}{p} X^T X$ et son vecteur propre dominant pour $n = p = 1000$.

Quelques résultats sur les modèles spike

Théorème ([Baik, Silverstein'06], [Paul'07])

Let

- ▶ Soit Z avec des entrées i.i.d. de moyenne nulle, variance 1 et $\mathbb{E}|Z_{ij}|^4 < \infty$
- ▶ $X = my^\top + Z$

Quelques résultats sur les modèles spike

Théorème ([Baik, Silverstein'06], [Paul'07])

Let

- ▶ Soit Z avec des entrées i.i.d. de moyenne nulle, variance 1 et $\mathbb{E}|Z_{ij}|^4 < \infty$
- ▶ $X = my^\top + Z$

Alors, quand $p, n \rightarrow$ avec $n/p \rightarrow c$,

Quelques résultats sur les modèles spike

Théorème ([Baik, Silverstein'06], [Paul'07])

Let

- ▶ Soit Z avec des entrées i.i.d. de moyenne nulle, variance 1 et $\mathbb{E}|Z_{ij}|^4 < \infty$
- ▶ $X = my^\top + Z$

Alors, quand $p, n \rightarrow$ avec $n/p \rightarrow c$,

- ▶ Si $\|\mu\|^2 > \sqrt{c}$

$$\lambda_\ell \left(\frac{1}{p} X^\top X \right) \xrightarrow{\text{p.s.}} 1 + \|\mu\|^2 + c \frac{1 + \|\mu\|^2}{\|\mu\|^2} > (1 + \sqrt{c})^2$$

Quelques résultats sur les modèles spike

Théorème ([Baik, Silverstein'06], [Paul'07])

Let

- ▶ Soit Z avec des entrées i.i.d. de moyenne nulle, variance 1 et $\mathbb{E}|Z_{ij}|^4 < \infty$
- ▶ $X = my^\top + Z$

Alors, quand $p, n \rightarrow$ avec $n/p \rightarrow c$,

- ▶ Si $\|\mu\|^2 > \sqrt{c}$

$$\lambda_\ell \left(\frac{1}{p} X^\top X \right) \xrightarrow{\text{p.s.}} 1 + \|\mu\|^2 + c \frac{1 + \|\mu\|^2}{\|\mu\|^2} > (1 + \sqrt{c})^2$$

- ▶ Pour $a, b \in \mathbb{R}^p$ déterministes et \hat{y} le vecteur propre correspondant à $\lambda_{\max} \left(\frac{1}{p} X^\top X \right)$,

$$a^\top \hat{y} \hat{y}^\top b - \frac{1 - c\|\mu\|^{-4}}{1 + c\|\mu\|^{-2}} a^\top \hat{y} \hat{y}^\top b \cdot \mathbf{1}_{\|\mu\|^2 > \sqrt{c}} \xrightarrow{\text{p.s.}} 0$$

Quelques résultats sur les modèles spike

Théorème ([Baik, Silverstein'06], [Paul'07])

Let

- ▶ Soit Z avec des entrées i.i.d. de moyenne nulle, variance 1 et $\mathbb{E}|Z_{ij}|^4 < \infty$
- ▶ $X = my^\top + Z$

Alors, quand $p, n \rightarrow$ avec $n/p \rightarrow c$,

- ▶ Si $\|\mu\|^2 > \sqrt{c}$

$$\lambda_\ell \left(\frac{1}{p} X^\top X \right) \xrightarrow{\text{p.s.}} 1 + \|\mu\|^2 + c \frac{1 + \|\mu\|^2}{\|\mu\|^2} > (1 + \sqrt{c})^2$$

- ▶ Pour $a, b \in \mathbb{R}^p$ déterministes et \hat{y} le vecteur propre correspondant à $\lambda_{\max} \left(\frac{1}{p} X^\top X \right)$,

$$a^\top \hat{y} \hat{y}^\top b - \frac{1 - c\|\mu\|^{-4}}{1 + c\|\mu\|^{-2}} a^\top \hat{y} \hat{y}^\top b \cdot \mathbf{1}_{\|\mu\|^2 > \sqrt{c}} \xrightarrow{\text{p.s.}} 0$$

En particulier,

$$|\hat{y}^\top y|^2 \xrightarrow{\text{p.s.}} \frac{1 - c\|\mu\|^{-4}}{1 + c\|\mu\|^{-2}} \cdot \mathbf{1}_{\|\mu\|^2 > \sqrt{c}}.$$

Quelques résultats sur les modèles spike




Figure: $|y^T y|^2$ simulé et valeur limite, $p/n = 1/3$, en variant $\|\mu\|^2$.

Outline

Introduction

Comportement de la matrice de Gram de vecteurs Gaussiens

Notion de vecteurs concentrés

Definition et propriétés

Données GAN : Un exemple de vecteurs concentrés

Comportement de la matrice de Gram de vecteurs concentrés

Application aux représentations CNN des images GAN

Outline

Introduction

Comportement de la matrice de Gram de vecteurs Gaussiens

Notion de vecteurs concentrés

Definition et propriétés

Données GAN : Un exemple de vecteurs concentrés

Comportement de la matrice de Gram de vecteurs concentrés

Application aux représentations CNN des images GAN

Notion de vecteurs concentrés

- ▶ **Observation:** La TMA prédit les performances en grande dimension sous des hypothèses **Gaussiennes** sur les données.

¹**Reminder:** $\mathcal{F} : E \rightarrow F$ is $\|\mathcal{F}\|_{lip}$ -Lipschitz if $\forall (x, y) \in E^2 : \|\mathcal{F}(x) - \mathcal{F}(y)\|_F \leq \|\mathcal{F}\|_{lip} \|x - y\|_E$.

Notion de vecteurs concentrés

- ▶ **Observation:** La TMA prédit les performances en grande dimension sous des hypothèses **Gaussiennes** sur les données.
- ▶ **MAIS** les données réelles sont difficilement **assimilable** à des vecteurs **Gaussiens**.

¹**Reminder:** $\mathcal{F} : E \rightarrow F$ is $\|\mathcal{F}\|_{lip}$ -Lipschitz if $\forall (x, y) \in E^2 : \|\mathcal{F}(x) - \mathcal{F}(y)\|_F \leq \|\mathcal{F}\|_{lip} \|x - y\|_E$.

Notion de vecteurs concentrés

- ▶ **Observation:** La TMA prédit les performances en grande dimension sous des hypothèses **Gaussiennes** sur les données.
- ▶ **MAIS** les données réelles sont difficilement **assimilable** à des vecteurs **Gaussiens**.
- ▶ Il se trouve que les vecteurs **Gaussiens** appartiennent à une classe plus large et plus utile de vecteurs aléatoires.

¹**Reminder:** $\mathcal{F} : E \rightarrow F$ is $\|\mathcal{F}\|_{lip}$ -Lipschitz if $\forall (x, y) \in E^2 : \|\mathcal{F}(x) - \mathcal{F}(y)\|_F \leq \|\mathcal{F}\|_{lip} \|x - y\|_E$.

Notion de vecteurs concentrés

- ▶ **Observation:** La TMA prédit les performances en grande dimension sous des hypothèses **Gaussiennes** sur les données.
- ▶ **MAIS** les données réelles sont difficilement **assimilable** à des vecteurs **Gaussiens**.
- ▶ Il se trouve que les vecteurs **Gaussiens** appartiennent à une classe plus large et plus utile de vecteurs aléatoires.

Definition

Etant donné un espace normé $(E, \|\cdot\|_E)$ et $q \in \mathbb{R}$, un vecteur aléatoire $\mathbf{z} \in E$ est q -exponentiellement **concentré** si pour toute fonction **1-Lipschitz**¹ $\mathcal{F} : \mathbb{R}^p \rightarrow \mathbb{R}$, il existe $C, c > 0$ tels que

$$\mathbb{P}\{|\mathcal{F}(\mathbf{z}) - \mathbb{E}\mathcal{F}(\mathbf{z})| > t\} \leq Ce^{-c t^q}$$

¹**Reminder:** $\mathcal{F} : E \rightarrow F$ is $\|\mathcal{F}\|_{lip}$ -Lipschitz if $\forall (x, y) \in E^2 : \|\mathcal{F}(x) - \mathcal{F}(y)\|_F \leq \|\mathcal{F}\|_{lip} \|x - y\|_E$.

Notion de vecteurs concentrés

- ▶ **Observation:** La TMA prédit les performances en grande dimension sous des hypothèses **Gaussiennes** sur les données.
- ▶ **MAIS** les données réelles sont difficilement **assimilable** à des vecteurs **Gaussiens**.
- ▶ Il se trouve que les vecteurs **Gaussiens** appartiennent à une classe plus large et plus utile de vecteurs aléatoires.

Definition

Etant donné un espace normé $(E, \|\cdot\|_E)$ et $q \in \mathbb{R}$, un vecteur aléatoire $\mathbf{z} \in E$ est q -exponentiellement **concentré** si pour toute fonction **1-Lipschitz**¹ $\mathcal{F} : \mathbb{R}^p \rightarrow \mathbb{R}$, il existe $C, c > 0$ tels que

$$\mathbb{P}\{|\mathcal{F}(\mathbf{z}) - \mathbb{E}\mathcal{F}(\mathbf{z})| > t\} \leq Ce^{-c t^q} \xrightarrow{\text{noté}} \boxed{\mathbf{z} \in \mathcal{O}(e^{-\cdot^q})}$$

¹**Reminder:** $\mathcal{F} : E \rightarrow F$ is $\|\mathcal{F}\|_{lip}$ -Lipschitz if $\forall (x, y) \in E^2 : \|\mathcal{F}(x) - \mathcal{F}(y)\|_F \leq \|\mathcal{F}\|_{lip} \|x - y\|_E$.

Notion de vecteurs concentrés

- ▶ **Observation:** La TMA prédit les performances en grande dimension sous des hypothèses **Gaussiennes** sur les données.
- ▶ **MAIS** les données réelles sont difficilement **assimilable** à des vecteurs **Gaussiens**.
- ▶ Il se trouve que les vecteurs **Gaussiens** appartiennent à une classe plus large et plus utile de vecteurs aléatoires.

Definition

Etant donné un espace normé $(E, \|\cdot\|_E)$ et $q \in \mathbb{R}$, un vecteur aléatoire $\mathbf{z} \in E$ est q -exponentiellement **concentré** si pour toute fonction **1-Lipschitz**¹ $\mathcal{F} : \mathbb{R}^p \rightarrow \mathbb{R}$, il existe $C, c > 0$ tels que

$$\mathbb{P}\{|\mathcal{F}(\mathbf{z}) - \mathbb{E}\mathcal{F}(\mathbf{z})| > t\} \leq Ce^{-c t^q} \xrightarrow{\text{noté}} \boxed{\mathbf{z} \in \mathcal{O}(e^{-\cdot^q})}$$

(P1) $\mathbf{X} \sim \mathcal{N}(0, I_p)$ is 2-exponentiellement **concentré**.

¹**Reminder:** $\mathcal{F} : E \rightarrow F$ is $\|\mathcal{F}\|_{lip}$ -Lipschitz if $\forall (x, y) \in E^2 : \|\mathcal{F}(x) - \mathcal{F}(y)\|_F \leq \|\mathcal{F}\|_{lip} \|x - y\|_E$.

Notion de vecteurs concentrés

- ▶ **Observation:** La TMA prédit les performances en grande dimension sous des hypothèses **Gaussiennes** sur les données.
- ▶ **MAIS** les données réelles sont difficilement **assimilable** à des vecteurs **Gaussiens**.
- ▶ Il se trouve que les vecteurs **Gaussiens** appartiennent à une classe plus large et plus utile de vecteurs aléatoires.

Definition

Etant donné un espace normé $(E, \|\cdot\|_E)$ et $q \in \mathbb{R}$, un vecteur aléatoire $\mathbf{z} \in E$ est q -exponentiellement **concentré** si pour toute fonction **1-Lipschitz**¹ $\mathcal{F} : \mathbb{R}^p \rightarrow \mathbb{R}$, il existe $C, c > 0$ tels que

$$\mathbb{P}\{|\mathcal{F}(\mathbf{z}) - \mathbb{E}\mathcal{F}(\mathbf{z})| > t\} \leq Ce^{-c t^q} \xrightarrow{\text{noté}} \boxed{\mathbf{z} \in \mathcal{O}(e^{-\cdot^q})}$$

(P1) $\mathbf{X} \sim \mathcal{N}(0, I_p)$ is 2-exponentiellement **concentré**.

(P2) Si $\mathbf{X} \in \mathcal{O}(e^{-\cdot^q})$ et \mathcal{G} est $\|\mathcal{G}\|_{lip}$ -**Lipschitz**, alors

$$\mathcal{G}(\mathbf{X}) \in \mathcal{O}\left(e^{-(\cdot/\|\mathcal{G}\|_{lip})^q}\right).$$

¹Reminder: $\mathcal{F} : E \rightarrow F$ is $\|\mathcal{F}\|_{lip}$ -Lipschitz if $\forall (x, y) \in E^2 : \|\mathcal{F}(x) - \mathcal{F}(y)\|_F \leq \|\mathcal{F}\|_{lip} \|x - y\|_E$.

Notion de vecteurs concentrés

- ▶ **Observation:** La TMA prédit les performances en grande dimension sous des hypothèses **Gaussiennes** sur les données.
- ▶ **MAIS** les données réelles sont difficilement **assimilable** à des vecteurs **Gaussiens**.
- ▶ Il se trouve que les vecteurs **Gaussiens** appartiennent à une classe plus large et plus utile de vecteurs aléatoires.

Definition

Etant donné un espace normé $(E, \|\cdot\|_E)$ et $q \in \mathbb{R}$, un vecteur aléatoire $\mathbf{z} \in E$ est q -exponentiellement **concentré** si pour toute fonction **1-Lipschitz**¹ $\mathcal{F} : \mathbb{R}^p \rightarrow \mathbb{R}$, il existe $C, c > 0$ tels que

$$\mathbb{P}\{|\mathcal{F}(\mathbf{z}) - \mathbb{E}\mathcal{F}(\mathbf{z})| > t\} \leq Ce^{-c t^q} \xrightarrow{\text{noté}} \boxed{\mathbf{z} \in \mathcal{O}(e^{-\cdot^q})}$$

(P1) $\mathbf{X} \sim \mathcal{N}(0, I_p)$ is 2-exponentiellement **concentré**.

(P2) Si $\mathbf{X} \in \mathcal{O}(e^{-\cdot^q})$ et \mathcal{G} est $\|\mathcal{G}\|_{lip}$ -**Lipschitz**, alors

$$\mathcal{G}(\mathbf{X}) \in \mathcal{O}\left(e^{-(\cdot/\|\mathcal{G}\|_{lip})^q}\right).$$

“Les vecteurs concentrés sont stable à travers des transformations Lipschitziennes.”

¹Reminder: $\mathcal{F} : E \rightarrow F$ is $\|\mathcal{F}\|_{lip}$ -Lipschitz if $\forall (x, y) \in E^2 : \|\mathcal{F}(x) - \mathcal{F}(y)\|_F \leq \|\mathcal{F}\|_{lip} \|x - y\|_E$.

Outline

Introduction

Comportement de la matrice de Gram de vecteurs Gaussiens

Notion de vecteurs concentrés


Definition et propriétés

Données GAN : Un exemple de vecteurs concentrés


Comportement de la matrice de Gram de vecteurs concentrés

Application aux représentations CNN des images GAN

Données GAN : Un exemple de vecteurs concentrés




Données GAN : Un exemple de vecteurs concentrés



$$\min_{\mathcal{G}} \max_{\mathcal{D}} \mathbb{E}_{x \sim p(x)} [\log \mathcal{D}(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - \mathcal{D}(\mathcal{G}(z)))]$$

Données GAN : Un exemple de vecteurs concentrés



$$\min_{\mathcal{G}} \max_{\mathcal{D}} \mathbb{E}_{x \sim p(x)} [\log \mathcal{D}(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - \mathcal{D}(\mathcal{G}(z)))]$$

On génère les données comme

$$\text{Image générée} = \mathcal{G}(\text{Gaussien})$$

Données GAN : Un exemple de vecteurs concentrés



Figure: Images générées par le modèle BigGAN [Brock et al, ICLR'19].

Données GAN : Un exemple de vecteurs concentrés



Figure: Images générées par le modèle BigGAN [Brock et al, ICLR'19].

Donnée GAN = $\mathcal{F}_1 \circ \mathcal{F}_2 \circ \dots \circ \mathcal{F}_N(\text{Gaussien})$

Données GAN : Un exemple de vecteurs concentrés



Figure: Images générées par le modèle BigGAN [Brock et al, ICLR'19].

$$\text{Donnée GAN} = \mathcal{F}_1 \circ \mathcal{F}_2 \circ \dots \circ \mathcal{F}_N(\text{Gaussien})$$

où les \mathcal{F}_i 's sont des couches Fully Connected, Convolutionnelles, Pooling et fonctions d'activation, des connexions résiduelles ou Batch Normalisation.

Données GAN : Un exemple de vecteurs concentrés



Figure: Images générées par le modèle BigGAN [Brock et al, ICLR'19].

$$\text{Donnée GAN} = \mathcal{F}_1 \circ \mathcal{F}_2 \circ \dots \circ \mathcal{F}_N(\text{Gaussien})$$

où les \mathcal{F}_i 's sont des couches Fully Connected, Convolutionnelles, Pooling et fonctions d'activation, des connexions résiduelles ou Batch Normalisation.

⇒ Les \mathcal{F}_i 's sont des opérations *Lipschitziennes*.

Données GAN : Un exemple de vecteurs concentrés

- ▶ **Couches Fully Connected Layers et Convolutionnelles** sont des opérations affines :

$$\mathcal{F}_i(x) = W_i x + b_i,$$

et $\|\mathcal{F}_i\|_{lip} = \sup_{u \neq 0} \frac{\|W_i u\|_p}{\|u\|_p}$, pour toute p -norme.

Données GAN : Un exemple de vecteurs concentrés

- ▶ **Couches Fully Connected Layers et Convolutionnelles** sont des opérations affines :

$$\mathcal{F}_i(x) = W_i x + b_i,$$

et $\|\mathcal{F}_i\|_{lip} = \sup_{u \neq 0} \frac{\|W_i u\|_p}{\|u\|_p}$, pour toute p -norme.

- ▶ **Pooling et Fonctions d'Activation** : Sont généralement au plus 1-Lipschitz par rapport à toute p -norme (e.g., ReLU and Max-pooling).

Données GAN : Un exemple de vecteurs concentrés

- ▶ **Couches Fully Connected Layers et Convolutionnelles** sont des opérations affines :

$$\mathcal{F}_i(x) = W_i x + b_i,$$

et $\|\mathcal{F}_i\|_{lip} = \sup_{u \neq 0} \frac{\|W_i u\|_p}{\|u\|_p}$, pour toute p -norme.

- ▶ **Pooling et Fonctions d'Activation** : Sont généralement au plus 1-Lipschitz par rapport à toute p -norme (e.g., ReLU and Max-pooling).
- ▶ **Connexions résiduelles** : $\mathcal{F}_i(x) = x + \mathcal{F}_i^{(1)} \circ \dots \circ \mathcal{F}_i^{(\ell)}(x)$
où les $\mathcal{F}_i^{(j)}$ sont des opérations Lipschitziennes, alors \mathcal{F}_i est Lipschitz avec une constante de Lipschitz bornée par $1 + \prod_{j=1}^{\ell} \|\mathcal{F}_i^{(j)}\|_{lip}$.
- ▶ ...

Mixture of Concentrated Vectors

Considérons des données distribuées dans k classes $\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_k$ telles que

$$X = [\underbrace{x_1, \dots, x_{n_1}}_{\in \mathcal{O}(e^{-\cdot q_1})}, \underbrace{x_{n_1+1}, \dots, x_{n_2}}_{\in \mathcal{O}(e^{-\cdot q_2})}, \dots, \underbrace{x_{n-n_k+1}, \dots, x_n}_{\in \mathcal{O}(e^{-\cdot q_k})}] \in \mathbb{R}^{p \times n}$$

Mixture of Concentrated Vectors

Considérons des données distribuées dans k classes $\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_k$ telles que

$$X = [\underbrace{x_1, \dots, x_{n_1}}_{\in \mathcal{O}(e^{-\cdot^{q_1}})}, \underbrace{x_{n_1+1}, \dots, x_{n_2}}_{\in \mathcal{O}(e^{-\cdot^{q_2}})}, \dots, \underbrace{x_{n-n_k+1}, \dots, x_n}_{\in \mathcal{O}(e^{-\cdot^{q_k}})}] \in \mathbb{R}^{p \times n}$$

On note

$$\mu_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i], \quad C_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i x_i^\top]$$

Mixture of Concentrated Vectors

Considérons des données distribuées dans k classes $\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_k$ telles que

$$X = [\underbrace{x_1, \dots, x_{n_1}}_{\in \mathcal{O}(e^{-\cdot^{q_1}})}, \underbrace{x_{n_1+1}, \dots, x_{n_2}}_{\in \mathcal{O}(e^{-\cdot^{q_2}})}, \dots, \underbrace{x_{n-n_k+1}, \dots, x_n}_{\in \mathcal{O}(e^{-\cdot^{q_k}})}] \in \mathbb{R}^{p \times n}$$

On note

$$\mu_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i], \quad C_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i x_i^T]$$

Hypothèses (Taux de croissance)

Quand $p \rightarrow \infty$,

Mixture of Concentrated Vectors

Considérons des données distribuées dans k classes $\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_k$ telles que

$$X = [\underbrace{x_1, \dots, x_{n_1}}_{\in \mathcal{O}(e^{-\cdot^{q_1}})}, \underbrace{x_{n_1+1}, \dots, x_{n_2}}_{\in \mathcal{O}(e^{-\cdot^{q_2}})}, \dots, \underbrace{x_{n-n_k+1}, \dots, x_n}_{\in \mathcal{O}(e^{-\cdot^{q_k}})}] \in \mathbb{R}^{p \times n}$$

On note

$$\mu_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i], \quad C_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i x_i^\top]$$

Hypothèses (Taux de croissance)

Quand $p \rightarrow \infty$,

1. $p/n \rightarrow c \in (0, \infty)$.

Mixture of Concentrated Vectors

Considérons des données distribuées dans k classes $\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_k$ telles que

$$X = [\underbrace{x_1, \dots, x_{n_1}}_{\in \mathcal{O}(e^{-\cdot^{q_1}})}, \underbrace{x_{n_1+1}, \dots, x_{n_2}}_{\in \mathcal{O}(e^{-\cdot^{q_2}})}, \dots, \underbrace{x_{n-n_k+1}, \dots, x_n}_{\in \mathcal{O}(e^{-\cdot^{q_k}})}] \in \mathbb{R}^{p \times n}$$

On note

$$\mu_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i], \quad C_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i x_i^\top]$$

Hypothèses (Taux de croissance)

Quand $p \rightarrow \infty$,

1. $p/n \rightarrow c \in (0, \infty)$.
2. Le nombre de classes k est borné.

Mixture of Concentrated Vectors

Considérons des données distribuées dans k classes $\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_k$ telles que

$$X = [\underbrace{x_1, \dots, x_{n_1}}_{\in \mathcal{O}(e^{-\cdot^{q_1}})}, \underbrace{x_{n_1+1}, \dots, x_{n_2}}_{\in \mathcal{O}(e^{-\cdot^{q_2}})}, \dots, \underbrace{x_{n-n_k+1}, \dots, x_n}_{\in \mathcal{O}(e^{-\cdot^{q_k}})}] \in \mathbb{R}^{p \times n}$$

On note

$$\mu_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i], \quad C_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i x_i^\top]$$

Hypothèses (Taux de croissance)

Quand $p \rightarrow \infty$,

1. $p/n \rightarrow c \in (0, \infty)$.
2. Le nombre de classes k est borné.
3. Pour tout $\ell \in [k]$, $\|\mu_\ell\| = \mathcal{O}(\sqrt{p})$.

Mixture of Concentrated Vectors

Considérons des données distribuées dans k classes $\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_k$ telles que

$$X = [\underbrace{x_1, \dots, x_{n_1}}_{\in \mathcal{O}(e^{-\cdot^{q_1}})}, \underbrace{x_{n_1+1}, \dots, x_{n_2}}_{\in \mathcal{O}(e^{-\cdot^{q_2}})}, \dots, \underbrace{x_{n-n_k+1}, \dots, x_n}_{\in \mathcal{O}(e^{-\cdot^{q_k}})}] \in \mathbb{R}^{p \times n}$$

On note

$$\mu_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i], \quad C_\ell = \mathbb{E}_{x_i \in \mathcal{C}_\ell}[x_i x_i^\top]$$

Hypothèses (Taux de croissance)

Quand $p \rightarrow \infty$,

1. $p/n \rightarrow c \in (0, \infty)$.
2. Le nombre de classes k est borné.
3. Pour tout $\ell \in [k]$, $\|\mu_\ell\| = \mathcal{O}(\sqrt{p})$.

Notation

$$Q(z) = (X^\top X/p + zI_n)^{-1}.$$

Outline

Introduction

Comportement de la matrice de Gram de vecteurs Gaussiens

Notion de vecteurs concentrés

Definition et propriétés

Données GAN : Un exemple de vecteurs concentrés

Comportement de la matrice de Gram de vecteurs concentrés

Application aux representations CNN des images GAN

Comportement de la matrice de Gram de vecteurs concentrés

Soient

$$G = \frac{1}{p} X^T X = \frac{1}{p} J M^T M J^T + \frac{1}{p} Z^T Z + * + o_p(1)$$

Comportement de la matrice de Gram de vecteurs concentrés

Soient

$$G = \frac{1}{p} X^T X = \frac{1}{p} J M^T M J^T + \frac{1}{p} Z^T Z + * + o_p(1)$$

L la densité spectrale empirique de G et U la matrice qui contient les vecteurs propres dominants de G . Alors

$$L = \frac{1}{n} \sum_i^n \delta_{\lambda_i}, \quad m_L(z) = \int_{\lambda} \frac{dL(\lambda)}{\lambda - z} = \frac{1}{n} \text{tr}(Q(-z))$$

$$UU^T = \frac{1}{2\pi i} \oint_{\gamma} Q(-z) dz$$

Comportement de la matrice de Gram de vecteurs concentrés

Soient

$$G = \frac{1}{p} X^T X = \frac{1}{p} J M^T M J^T + \frac{1}{p} Z^T Z + * + o_p(1)$$

L la densité spectrale empirique de G et U la matrice qui contient les vecteurs propres dominants de G . Alors

$$L = \frac{1}{n} \sum_i^n \delta_{\lambda_i}, \quad m_L(z) = \int_{\lambda} \frac{dL(\lambda)}{\lambda - z} = \frac{1}{n} \text{tr}(Q(-z))$$

$$UU^T = \frac{1}{2\pi i} \oint_{\gamma} Q(-z) dz$$

⇒ Analyser le comportement de la résolvant $Q(z) = (G + zI_n)^{-1}$.

Comportement de la matrice de Gram de vecteurs concentrés

Théorème

Sous les hypothèses précédentes, on a $Q(z) \in \mathcal{O}(e^{-(\sqrt{p} \cdot)^q})$ in $(\mathbb{R}^{n \times n}, \|\cdot\|)$. De plus,

$$\left\| \mathbb{E}[Q(z)] - \tilde{Q}(z) \right\| = \mathcal{O}\left(\sqrt{\frac{\log p}{p}}\right) \text{ où } \tilde{Q}(z) = \frac{1}{z} \Lambda(z) + \frac{1}{p z} J \Omega(z) J^T$$

Comportement de la matrice de Gram de vecteurs concentrés

Théorème

Sous les hypothèses précédentes, on a $Q(z) \in \mathcal{O}(e^{-(\sqrt{p} \cdot)^q})$ in $(\mathbb{R}^{n \times n}, \|\cdot\|)$. De plus,

$$\left\| \mathbb{E}[Q(z)] - \tilde{Q}(z) \right\| = \mathcal{O}\left(\sqrt{\frac{\log p}{p}}\right) \text{ où } \tilde{Q}(z) = \frac{1}{z} \Lambda(z) + \frac{1}{pz} J \Omega(z) J^T$$

$$\text{avec } \Lambda(z) = \text{diag} \left\{ \frac{1_{n_\ell}}{1 + \delta_\ell(z)} \right\}_{\ell=1}^k \text{ et } \Omega(z) = \text{diag}\{\mu_\ell^T \tilde{R}(z) \mu_\ell\}_{\ell=1}^k$$

Comportement de la matrice de Gram de vecteurs concentrés

Théorème

Sous les hypothèses précédentes, on a $Q(z) \in \mathcal{O}(e^{-(\sqrt{p} \cdot)^q})$ in $(\mathbb{R}^{n \times n}, \|\cdot\|)$. De plus,

$$\left\| \mathbb{E}[Q(z)] - \tilde{Q}(z) \right\| = \mathcal{O}\left(\sqrt{\frac{\log p}{p}}\right) \text{ où } \tilde{Q}(z) = \frac{1}{z} \Lambda(z) + \frac{1}{pz} J \Omega(z) J^\top$$

avec $\Lambda(z) = \text{diag} \left\{ \frac{1_{n_\ell}}{1 + \delta_\ell(z)} \right\}_{\ell=1}^k$ et $\Omega(z) = \text{diag}\{\mu_\ell^\top \tilde{R}(z) \mu_\ell\}_{\ell=1}^k$

$$\tilde{R}(z) = \left(\frac{1}{k} \sum_{\ell=1}^k \frac{C_\ell}{1 + \delta_\ell(z)} + z I_p \right)^{-1}$$

Comportement de la matrice de Gram de vecteurs concentrés

Théorème

Sous les hypothèses précédentes, on a $Q(z) \in \mathcal{O}(e^{-(\sqrt{p} \cdot)^q})$ in $(\mathbb{R}^{n \times n}, \|\cdot\|)$. De plus,

$$\left\| \mathbb{E}[Q(z)] - \tilde{Q}(z) \right\| = \mathcal{O}\left(\sqrt{\frac{\log p}{p}}\right) \text{ où } \tilde{Q}(z) = \frac{1}{z} \Lambda(z) + \frac{1}{pz} J \Omega(z) J^\top$$

avec $\Lambda(z) = \text{diag} \left\{ \frac{1_{n_\ell}}{1 + \delta_\ell(z)} \right\}_{\ell=1}^k$ et $\Omega(z) = \text{diag}\{\mu_\ell^\top \tilde{R}(z) \mu_\ell\}_{\ell=1}^k$

$$\tilde{R}(z) = \left(\frac{1}{k} \sum_{\ell=1}^k \frac{C_\ell}{1 + \delta_\ell(z)} + z I_p \right)^{-1}$$

avec $\delta(z) = [\delta_1(z), \dots, \delta_k(z)]$ l'unique point fixe du système d'équations suivant

$$\delta_\ell(z) = \text{tr} \left(C_\ell \left(\frac{1}{k} \sum_{j=1}^k \frac{C_j}{1 + \delta_j(z)} + z I_p \right)^{-1} \right) \text{ pour chaque } \ell \in [k].$$

Comportement de la matrice de Gram de vecteurs concentrés

Théorème

Sous les hypothèses précédentes, on a $Q(z) \in \mathcal{O}(e^{-(\sqrt{p} \cdot)^q})$ in $(\mathbb{R}^{n \times n}, \|\cdot\|)$. De plus,

$$\left\| \mathbb{E}[Q(z)] - \tilde{Q}(z) \right\| = \mathcal{O}\left(\sqrt{\frac{\log p}{p}}\right) \text{ où } \tilde{R}(z) = \frac{1}{z} \Lambda(z) + \frac{1}{pz} J \Omega(z) J^T$$

avec $\Lambda(z) = \text{diag} \left\{ \frac{1_{n_\ell}}{1 + \delta_\ell(z)} \right\}_{\ell=1}^k$ et $\Omega(z) = \text{diag}\{\mu_\ell^\top \tilde{R}(z) \mu_\ell\}_{\ell=1}^k$

$$\tilde{R}(z) = \left(\frac{1}{k} \sum_{\ell=1}^k \frac{\textcolor{red}{C}_\ell}{1 + \delta_\ell(z)} + z I_p \right)^{-1}$$

avec $\delta(z) = [\delta_1(z), \dots, \delta_k(z)]$ l'unique point fixe du système d'équations suivant

$$\delta_\ell(z) = \text{tr} \left(\textcolor{red}{C}_\ell \left(\frac{1}{k} \sum_{j=1}^k \frac{\textcolor{red}{C}_j}{1 + \delta_j(z)} + z I_p \right)^{-1} \right) \text{ pour chaque } \ell \in [k].$$

Comportement de la matrice de Gram de vecteurs concentrés

Théorème

Sous les hypothèses précédentes, on a $Q(z) \in \mathcal{O}(e^{-(\sqrt{p} \cdot)^q})$ in $(\mathbb{R}^{n \times n}, \|\cdot\|)$. De plus,

$$\left\| \mathbb{E}[Q(z)] - \tilde{Q}(z) \right\| = \mathcal{O}\left(\sqrt{\frac{\log p}{p}}\right) \text{ où } \tilde{R}(z) = \frac{1}{z} \Lambda(z) + \frac{1}{pz} J \Omega(z) J^T$$

$$\text{avec } \Lambda(z) = \text{diag} \left\{ \frac{1_{n_\ell}}{1 + \delta_\ell(z)} \right\}_{\ell=1}^k \text{ et } \Omega(z) = \text{diag}\{\mu_\ell^\top \tilde{R}(z) \mu_\ell\}_{\ell=1}^k$$

$$\tilde{R}(z) = \left(\frac{1}{k} \sum_{\ell=1}^k \frac{\textcolor{red}{C}_\ell}{1 + \delta_\ell(z)} + z I_p \right)^{-1}$$

avec $\delta(z) = [\delta_1(z), \dots, \delta_k(z)]$ l'unique point fixe du système d'équations suivant

$$\delta_\ell(z) = \text{tr} \left(\textcolor{red}{C}_\ell \left(\frac{1}{k} \sum_{j=1}^k \frac{\textcolor{red}{C}_j}{1 + \delta_j(z)} + z I_p \right)^{-1} \right) \text{ pour chaque } \ell \in [k].$$

Observation clé : Seulement les moments d'ordre un et deux sont importants !

Outline

Introduction

Comportement de la matrice de Gram de vecteurs Gaussiens

Notion de vecteurs concentrés


Definition et propriétés

Données GAN : Un exemple de vecteurs concentrés


Comportement de la matrice de Gram de vecteurs concentrés

Application aux representations CNN des images GAN

Application aux représentations CNN des images GAN




Application aux représentations CNN des images GAN





- ▶ Les représentations CNN correspondent à l'**avant dernière** couche du réseau.

Application aux représentations CNN des images GAN



- ▶ Les représentations CNN correspondent à l'**avant dernière** couche du réseau.
- ▶ Architectures couramment utilisées en pratique : **Resnet**, **VGG**, **Densenet**.

Application aux représentations CNN des images GAN



Application aux représentations CNN des images GAN

Real Images




GAN Images




Application aux représentations CNN des images GAN

GAN Images



Real Images



Merci pour votre attention !